Machine Learning Tutorial - Kaggle

Seil Na, Youngjae Yu

Sep 6, 2017

https://seilna.github.io/ml-tutorial

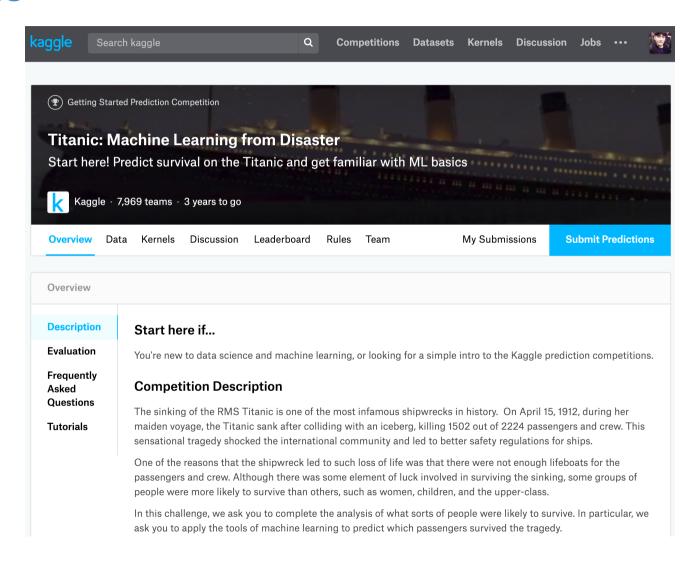


About

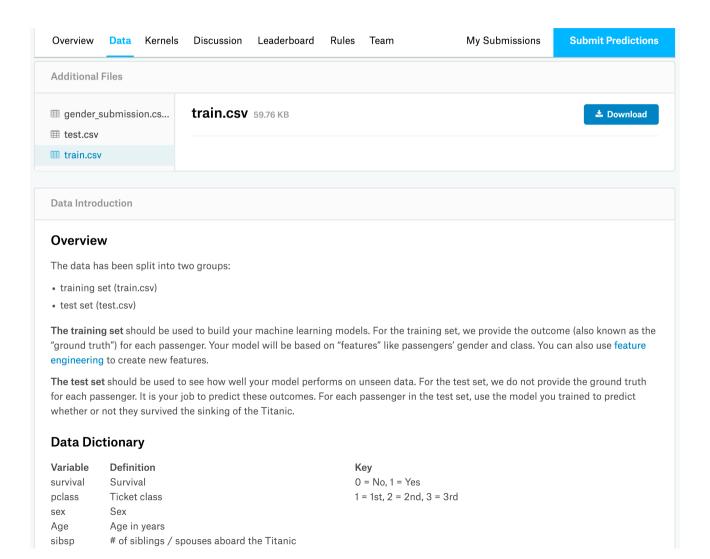
- Kaggle: Titanic
- Overview
- Data I/O (Today!)
- Model
- Loss & Optimization
- Visualize training stats
- Inference: Saving and Loading Variables

Clone

git clone https://github.com/seilna/ml-practice.git



Data



train.csv: 891 명에 대한 정보와 생존 여부(0, 1)

	Α	В	С	D	Е	F	G	Н		1	J	K	L
	Passengerld S	Survived	Pclass	Name	Sex	Age	SibSp	Parch		Ticket	Fare	Cabin	Embarked
2	1		0	3 Braund, Mr.	(male	2:	2	1	0	A/5 21171	7.25		S
3	2		1	1 Cumings, M	rs female	38	3	1	0	PC 17599	71.2833	C85	C
1	3		1	3 Heikkinen, N	1 female	20	5	0	0	STON/O2. 31	7.925		S
5	4		1	1 Futrelle, Mrs	. female	3.	5	1	0	113803	53.1	C123	S
5	5		0	3 Allen, Mr. W	il male	3.	5	0	0	373450	8.05		S
7	6		0	3 Moran, Mr	la male			0	0	330877	8.4583		Q
3	7		0	1 McCarthy, M	lı male	5-	4	0	0	17463	51.8625	E46	S
)	8		0	3 Palsson, Mas	stmale		2	3	1	349909	21.075		S
0	9		1	3 Johnson, Mr	s female	2	7	0	2	347742	11.1333		S
1	10		1	2 Nasser, Mrs.	female	1.	4	1	0	237736	30.0708		C
2	11		1	3 Sandstrom,	V female		4	1	1	PP 9549	16.7	G6	S
3	12		1	1 Bonnell, Mis	s female	5	3	0	0	113783	26.55	C103	S
4	13		0	3 Saundercock	, male	20)	0	0	A/5. 2151	8.05		S
5	14		0	3 Andersson, I	v male	3:	9	1	5	347082	31.275		S
6	15		0	3 Vestrom, Mi	s female	1.	4	0	0	350406	7.8542		S
7	16		1	2 Hewlett, Mrs	s. female	5.	5	0	0	248706	16		S
8	17		0	3 Rice, Master	. male		2	4	1	382652	29.125		Q
9	18		1	2 Williams, Mr	. male			0	0	244373	13		S
0	19		0	3 Vander Plan	k female	3	1	1	0	345763	18		S
1	20		1	3 Masselmani,	female			0	0	2649	7.225		С
2	21		0	2 Fynney, Mr.	J male	3.	5	0	0	239865	26		S
3	22		1	2 Beesley, Mr.	l male	34	4	0	0	248698	13	D56	S
4	23		1	3 McGowan, N	/I female	1:	5	0	0	330923	8.0292		Q

test.csv: 약 400 명에 대한 정보가 주어졌을 때, 생존 여부를 추측

	Α	В	С	D	Е	F	G		Н	I	J	K
1	Passengerld	Pclass	Name	Sex	Age	SibSp	Parch		Ticket	Fare	Cabin	Embarked
2	892	3	Kelly, Mr. Jan	male	34.5)	0	330911	7.8292		Q
3	893	3	Wilkes, Mrs	lfemale	47		1	0	363272	7		S
4	894	2	2 Myles, Mr. Th	male	62		0	0	240276	9.6875		Q
5	895	3	8 Wirz, Mr. Alb	male	27)	0	315154	8.6625		S
6	896	3	B Hirvonen, Mr	female	22		1	1	3101298	12.2875		S
7	897	3	Svensson, Mr	male	14)	0	7538	9.225		S
8	898	3	Connolly, Mis	female	30		0	0	330972	7.6292		Q
9	899	2	Caldwell, Mr.	male	26		1	1	248738	29		S
10	900	3	Abrahim, Mrs	female	18)	0	2657	7.2292		С
11	901	3	B Davies, Mr. Jo	male	21		2	0	A/4 48871	24.15		S
12	902	3	B Ilieff, Mr. Ylio	male)	0	349220	7.8958		S
13	903	•	Jones, Mr. Ch	male	46)	0	694	26		S
14	904	•	Snyder, Mrs.	.female	23		1	0	21228	82.2667	B45	S
15	905	2	2 Howard, Mr.	male	63		1	0	24065	26		S
16	906	•	Chaffee, Mrs.	female	47		1	0	W.E.P. 5734	61.175	E31	S
17	907	2	del Carlo, Mr	female	24		1	0	SC/PARIS 216	27.7208		С
18	908	2	Keane, Mr. D	male	35)	0	233734	12.35		Q
19	909	3	Assaf, Mr. Ge	male	21)	0	2692	7.225		С
20	910	3	Ilmakangas, N	female	27		1	0	STON/O2. 31	7.925		S
21	911	3	Assaf Khalil, I	female	45)	0	2696	7.225		С

gender_submission.csv

Download

```
train.csv: wget https://www.kaggle.com/c/titanic/download/train.csv
test.csv: wget https://www.kaggle.com/c/titanic/download/test.csv
git clone https://github.com/seilna/ml-practice.git
```

Code

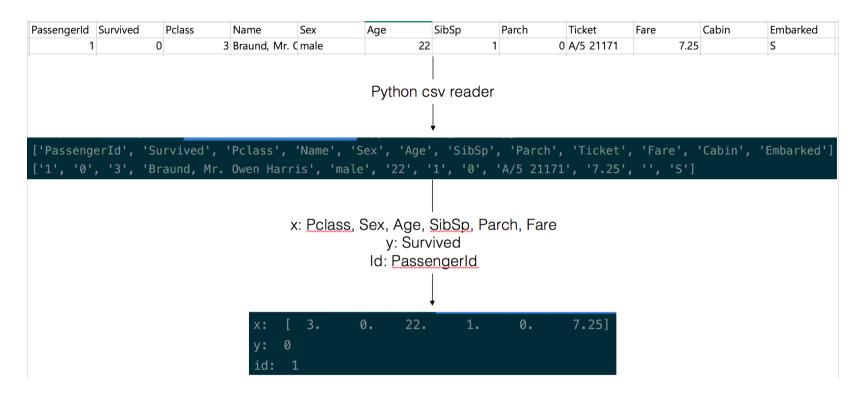
reader.py:raw_data train.csv / test.csv 를 읽어 numpy array로 변환하고, batching하는 코드 포함

reader_answer.py : Quiz에 대한 정답(나중에 보시는 것을 추천)

reader.py

- 보통 python class style 로 구성한다
- *.csv 파일을 읽고, 이를 numpy array 형태로 변환한다
- 구성한 numpy array로부터 batch_size 개 만큼의 example로 이루어진 batch 를 가져오는 next batch 함수를 method로 갖는다

.csv \rightarrow np.array (raw_to_vector())



.csv \rightarrow np.array (raw_to_vector())

전체 training examples 개수가 891개이고,

각 example당 x.shape=(6), y.shape=(1), id.shape=(1)

이므로, 모든 example에 대한 shape은 x.shape=(891, 6), y.shape=(891), id.shape=(891)

Batching

다음과 같은 기능을 하는 함수 next_batch()를 reader class의 method로 만들자

- 모든 training example x = (891, 6), y = (891), id = (891) 중에서
- batch를 구성하기 위해 batch_size 개 만큼의 example을 랜덤으로 가져온다
- 따라서, x_batch = (batch_size, 6), y_batch = (batch_size), id_batch = (batch_size)

Batching

다음과 같은 기능을 하는 함수 next_batch()를 reader class의 method로 만들자

- 단, 같은 epoch 내에서는 random으로 가져오는 example들이 겹쳐서는 안된다
- 또한, 1 epoch를 돌 때 마다, 모든 example들에 대한 순서를 섞어주어야 (shuffle) 한다

Practice (1)

여러분만의 reader.py 를 구현해보세요!

• sample code의 reader.py는 참고만하여 직접 새로 구현하시는 것을 추천드립니다

Practice (2)

reader.py 이 다음과 같은 기능을 갖도록 수정해보세요!

- 891 개 training example을 800개 train/ 100개 validation example로 split하여 따로 관리(보관)
- 따라서, next_batch() 함수도 train batch를 불러올 때/validation batch를 불러올 때 각각 다르게 동작해야 함
- 충분히 고민해보고, 잘 감이 안잡힌다면 reader_answer.py 를 참고해보세요

Thank You!

@Seil Na, @Youngjae Yu